Projekt u R-u

Statistička analiza podataka

Iva Rengel, Matea Bušić, Marta Bandur, Karla Budimir

ak. g. 2024./25.

Uvod

Opis problema i cilj projekta

Dva glavna pristupa u marketingu za koje se poduzeća opredjeljuju jesu masovne marketinške kampanje i ciljani marketing. Za razliku od masovnih marketinških kampanja koje su usmjerene na široku publiku, ciljani je marketing usmjeren na specifičnu skupinu potrošača.

U datoteci `data.csv` dan nam je skup podataka o jednoj ciljanoj telefonskoj marketinškoj kampanji koju je provela jedna banka. Među dostupnim varijablama nalaze se neki osnovni sociodemografski podaci o klijentu, podaci o odnosu i kontaktu klijenta s bankom, te podaci o uspješnosti provedene ciljane marketinške kampanje.

Cilj je našeg projekta statističkom analizom podataka odgovoriti na četiri istraživačka pitanja:

- Postoji li zavisnost između zanimanja i bračnog statusa klijenta?
- Imaju li klijenti s otvorenim kreditom više novca na računu od ostalih klijenata?

- Postoji li razlika trajanja poziva marketinške kampanje među klijentima različitog stupnja obrazovanja?
- Mogu li dostupne varijable predvidjeti uspješnost marketinške kampanje?

Opis skupa podataka

Učitajmo skup podataka `data.csv` u R i sažmimo ga.

```
data <- read.csv("/Users/Home/Desktop/SAP projekt/data.csv")
summary(data)
```

```
##       age            job            marital_status      education
##  Min.   :18.00   Length:45211       Length:45211       Length:45211
##  1st Qu.:33.00   Class :character   Class :character   Class :character
##  Median :39.00   Mode  :character   Mode  :character   Mode  :character
##  Mean   :40.94
##  3rd Qu.:48.00
##  Max.   :95.00
##    default            balance       housing_loan       personal_loan
##  Length:45211       Min.   : -8019   Length:45211       Length:45211
##  Class :character   1st Qu.:    72   Class :character   Class :character
##  Mode  :character   Median :   448   Mode  :character   Mode  :character
##                     Mean   :  1362
##                     3rd Qu.:  1428
##                     Max.   :102127
##    contact          last_contact_day last_contact_month last_contact_duration
##  Length:45211       Min.   : 1.00    Length:45211       Min.   :   0.0
##  Class :character   1st Qu.: 8.00    Class :character   1st Qu.: 103.0
##  Mode  :character   Median :16.00    Mode  :character   Median : 180.0
##                     Mean   :15.81                       Mean   : 258.2
##                     3rd Qu.:21.00                       3rd Qu.: 319.0
##                     Max.   :31.00                       Max.   :4918.0
##  campaign_contacts_count days_from_previous_campaign_contact
##  Min.   : 1.000          Min.   : -1.0
```

```
##  1st Qu.: 1.000          1st Qu.: -1.0
##  Median : 2.000          Median : -1.0
##  Mean   : 2.764          Mean   : 40.2
##  3rd Qu.: 3.000          3rd Qu.: -1.0
##  Max.   :63.000          Max.   :871.0
##  previous_contacts_count previous_campaign_outcome term_deposit_accepted
##  Min.   :  0.0000        Length:45211              Length:45211
##  1st Qu.:  0.0000        Class :character          Class :character
##  Median :  0.0000        Mode  :character          Mode  :character
##  Mean   :  0.5803
##  3rd Qu.:  0.0000
##  Max.   :275.0000
```

Istraživačka pitanja

Nezavisnost zaposlenja i bračnog statusa

Promatrane značajke zaposlenja i bračnog statusa obje su kategoričke varijable, gdje zaposlenje ima 12 kategorija:

- admin
- blue-collar
- enterprenour
- housemaid
- managment
- retired
- self-employed
- services
- student
- technician

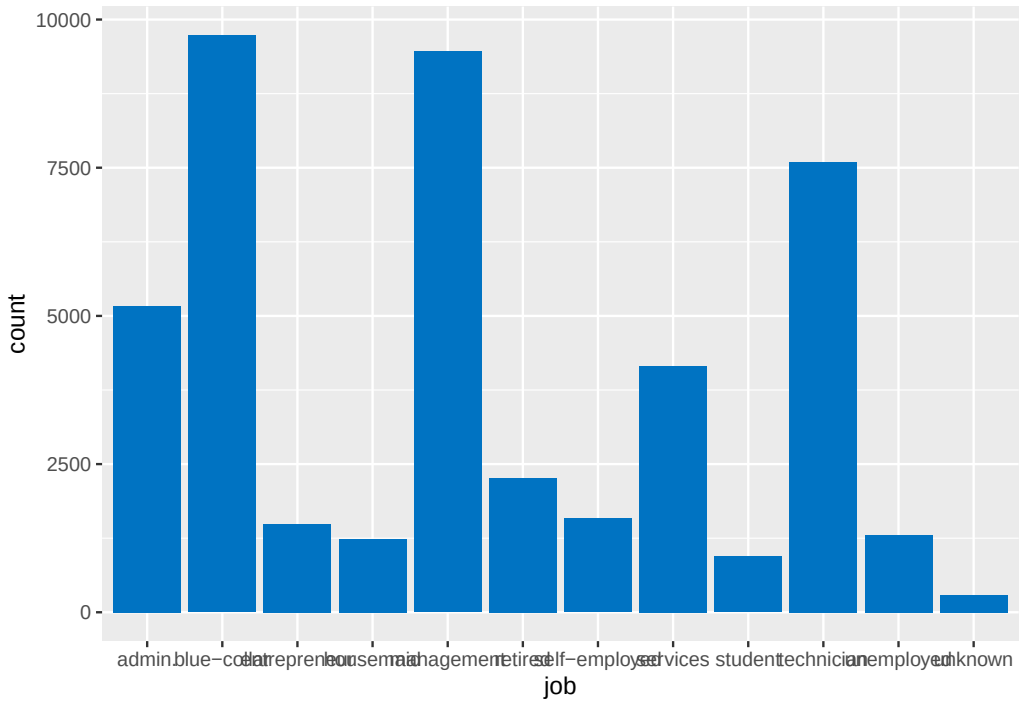
- unemployed
- unknown

a bračni status sljedeće tri kategorije:

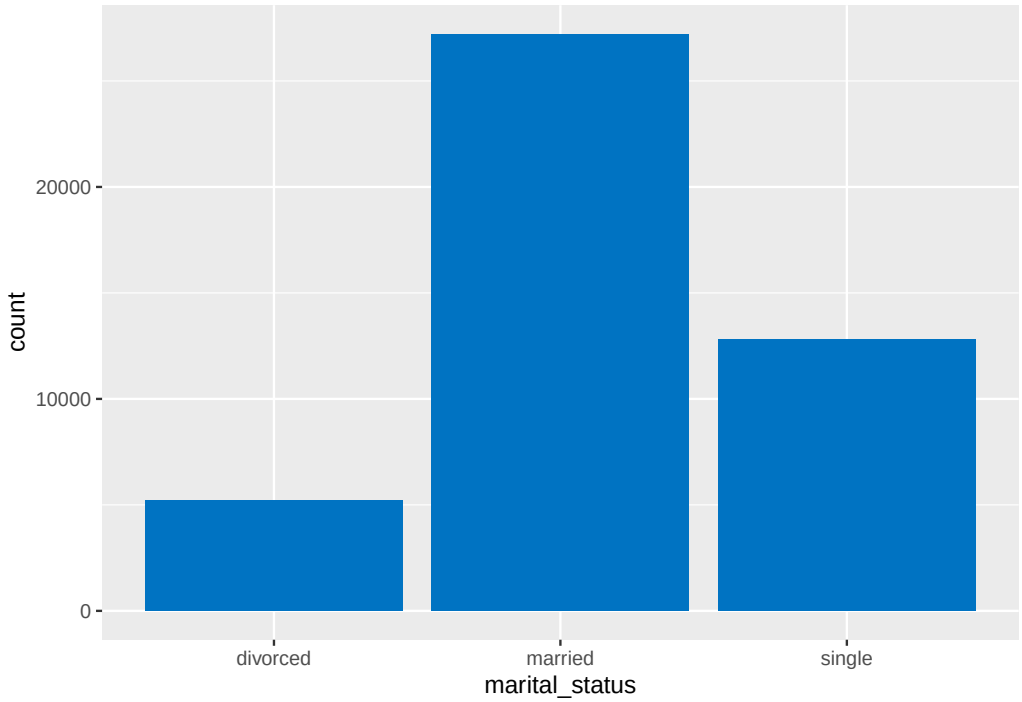
- single
- married
- divorced

Pogled na raspodijelu unutar kategorija vidljiv je na sljedećim grafovima:

```
library(ggplot2)
ggplot(data, aes(job)) +
     geom_bar(fill = "#0073C2FF")
```



```
ggplot(data, aes(marital_status)) +
     geom_bar(fill = "#0073C2FF")
```



Za pogled na zavisnosti među varijablama koristiti ćemo Chi kvadratni test nezavisnosti kategoričkih varijabli.

H_0: Valijable bračni status i zaposlenje su nezavisne H_1: Postoji zavisnost među varijablama bračni status i zaposlenje

Provest ćemo test sljedećom funkcijom:

```
test <- chisq.test(table(data$job, data$marital_status))
test
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(data$job, data$marital_status)
## X-squared = 3837.6, df = 22, p-value < 2.2e-16
```

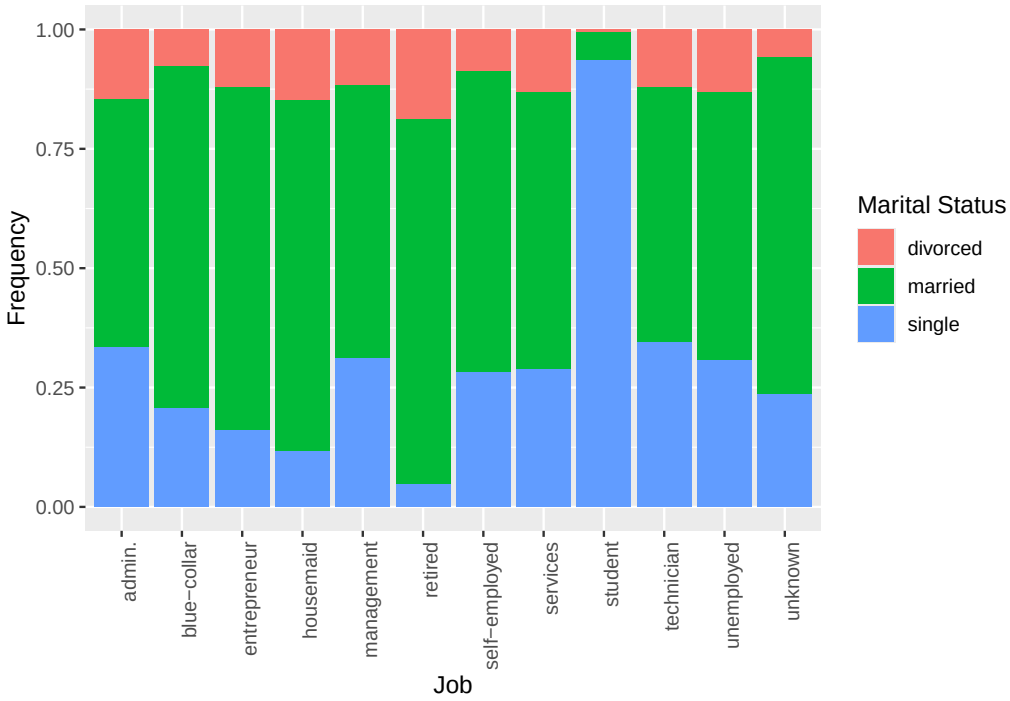
S obzirom da je p-vrijednost manja od početno definirane alfe (p-vrijednost $p = 2.2e-16 > 0.05 = \alpha$), odbacujemo H_0 u korist H_1, te zbog izrazito male p-vrijednosti podosta smo sigurni u ovu odluku. Odbacijemo pretpostavku da su varijable nezavisne, iz čega proizlazi da su zavisne. No test nam sam po sebi ne daje uvid u to na koji način jedna varijabla ovisi o drugoj.

```
test$stdres
```

```
##
##                     divorced      married       single
##   admin.          7.14949151 -12.66681212   8.69898436
##   blue-collar   -13.29310338  25.94782054 -18.77839808
##   entrepreneur    0.63941017   9.42339412 -10.69448703
##   housemaid       3.71531642   9.74190306 -13.22070945
##   management      0.78643321  -6.92318355   6.96669411
##   retired        11.09502934  16.22096158 -25.49253926
##   self-employed  -3.35873628   2.22664401  -0.03938037
##   services        3.59974057  -3.10764204   0.82603159
##   student       -10.54580419 -34.41843750  44.88020469
##   technician      1.97191300 -13.38495606  13.14910200
##   unemployed      1.84326976  -3.06201353   2.02135275
##   unknown        -2.99419820   3.57985245  -1.76840973
```

Dobiveni rezuduali pružaju nam dublji uvid u zavisnost pojedinih kategorija varijabli. Najznačajnije zavisnosti Uočavamo kod studenata, koji su u puno većem omjeru "single" u usporedbi s ostalim zaposlenjima, što je obrnut slučaj za umirovljene osobe. Umirovljenici su također u prosjeku češće rastavljeni, dok su "blue-collar" radnici češće oženjeni negoli nekog drugog bračnog statusa.

```
contingency_table <- table(data$job, data$marital_status)
mosaic_data <- as.data.frame(as.table(contingency_table))
ggplot(mosaic_data, aes(x = Var1, y = Freq, fill = Var2)) +
  geom_bar(stat = "identity", position = "fill") +
  theme(axis.text.x = element_text(angle = 90, hjust = 1)) +
  labs(x = "Job", fill = "Marital Status", y = "Frequency")
```



Imaju li klijenti s otvorenim kreditom više novca na računu od ostalih klijenata?

Kako bismo provjerili imaju li klijenti s otvorenim kreditom više novaca od ostalih klijenata, najprije moramo razdvojiti stanja računa klijenata s otvorenim kreditom od onih bez kredita te proučiti kako se ponašaju vrijednosti.

Među varijablama imamo dvije vrste kredita stambeni i nenamijenski, za svaki od njih napravit ćemo zasebnu analizu.

```
balance_with_housing_loan <- data$balance[data$housing_loan == "yes"]
balance_with_personal_loan <- data$balance[data$personal_loan == "yes"]
balance_without_loan <- data$balance[data$housing_loan == "no"
                                     & data$personal_loan == "no"]
#stambeni
mean_with_h <- mean(balance_with_housing_loan, na.rm = TRUE)
mean_with_h
```

```
## [1] 1175.103
```

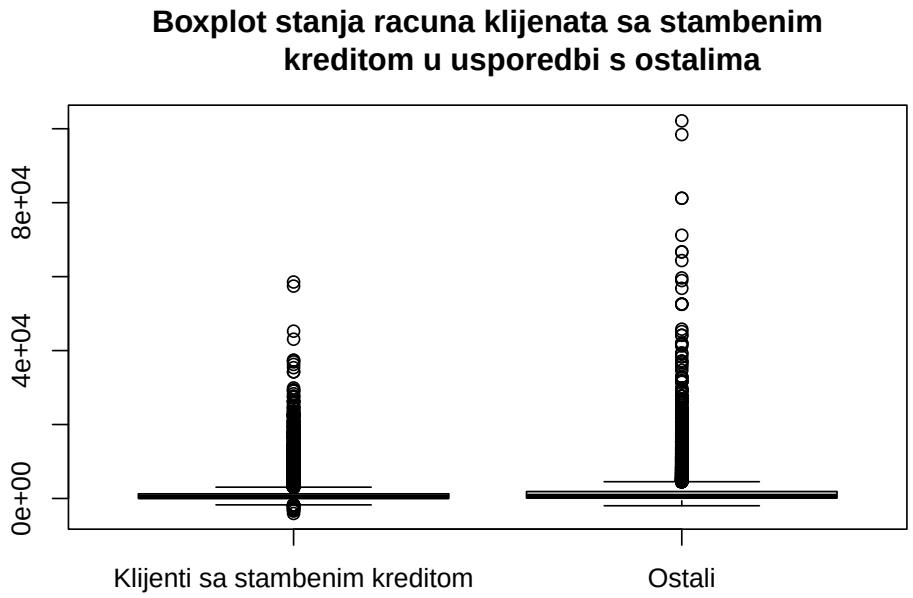
```
#nenamijenski
mean_with_p <- mean(balance_with_personal_loan, na.rm = TRUE)
mean_with_p
```

```
## [1] 774.3099
```

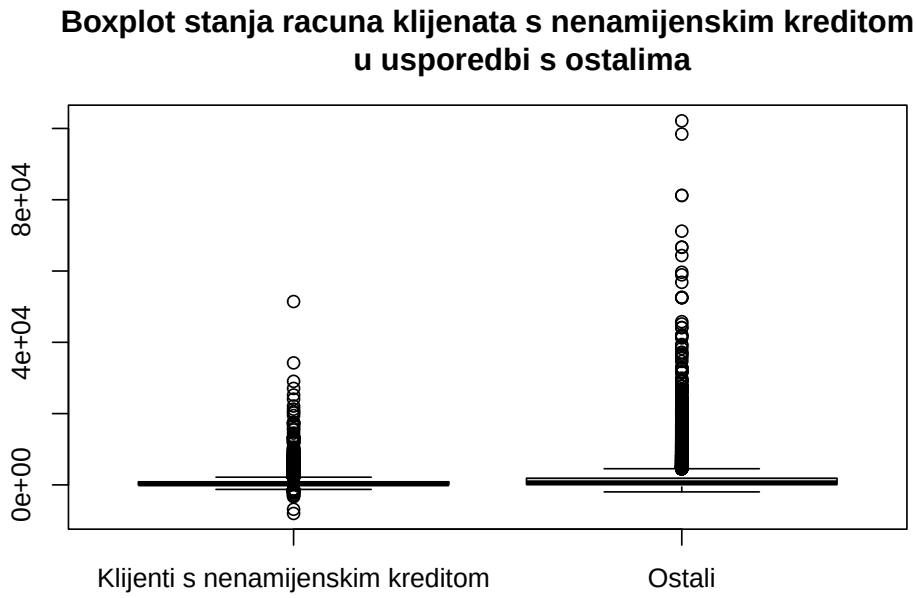
```
#ostali
mean_without <- mean(balance_without_loan, na.rm = TRUE)
mean_without
```

```
## [1] 1737.607
```

```
boxplot(balance_with_housing_loan, balance_without_loan,
        names = c('Klijenti sa stambenim kreditom',
                  'Ostali'),
        main='Boxplot stanja računa klijenata sa stambenim
        kreditom u usporedbi s ostalima')
```




```
boxplot(balance_with_personal_loan, balance_without_loan,
        names = c('Klijenti s nenamijenskim kreditom',
                  'Ostali'),
        main='Boxplot stanja računa klijenata s nenamijenskim kreditom
        u usporedbi s ostalima')
```



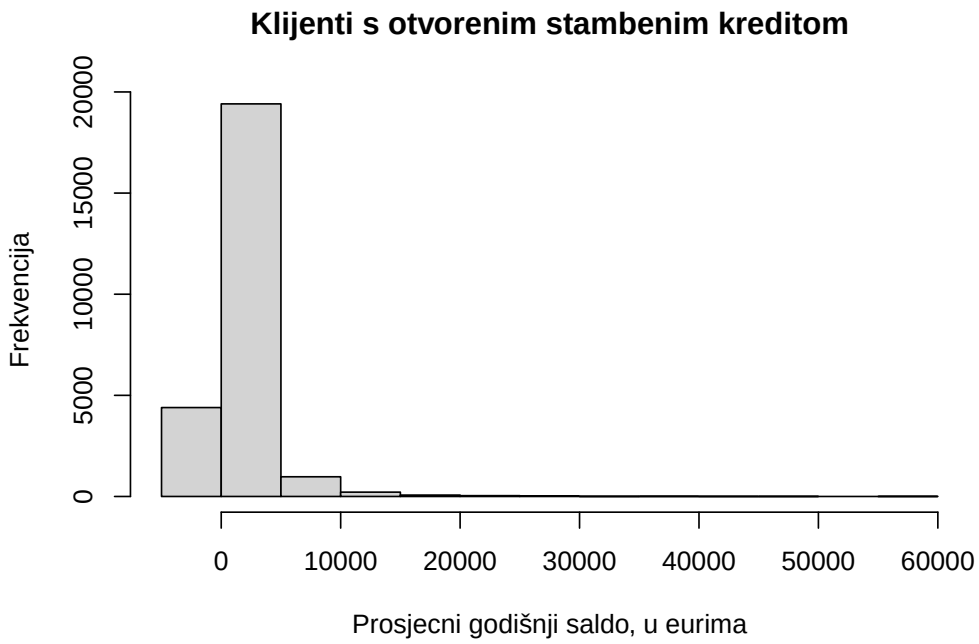
Nema indikacija da klijenti s otvorenim kreditom imaju više novca na računu od ostalih klijenata.

Kako bismo odgovorili na pitanje imaju li klijenti s otvorenim kreditom više novaca na računu od ostalih klijenata, trebamo usporediti prosječne vrijednosti dviju grupa; klijenata s otvorenim kreditom i ostalim klijentima.

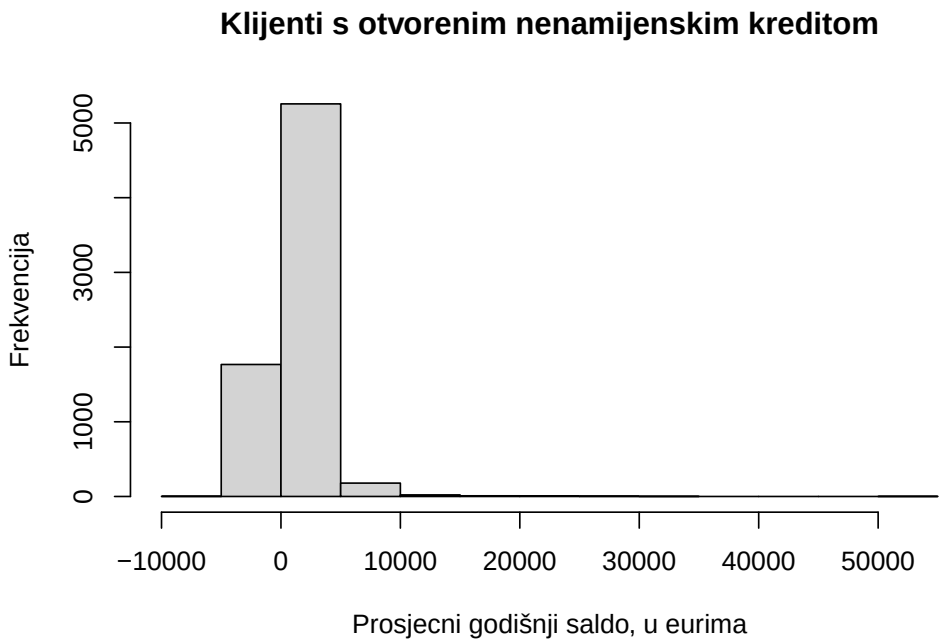
Ispitivanje ćemo provesti t-testom, no prije toga moramo provjeriti jesu li zadovoljene pretpostavke nezavisnosti i normalne distribucije.

Kako bismo mogli utvrditi jesu li podaci normalno distribuirani koristimo histograme, Q-Q plotove te testove.

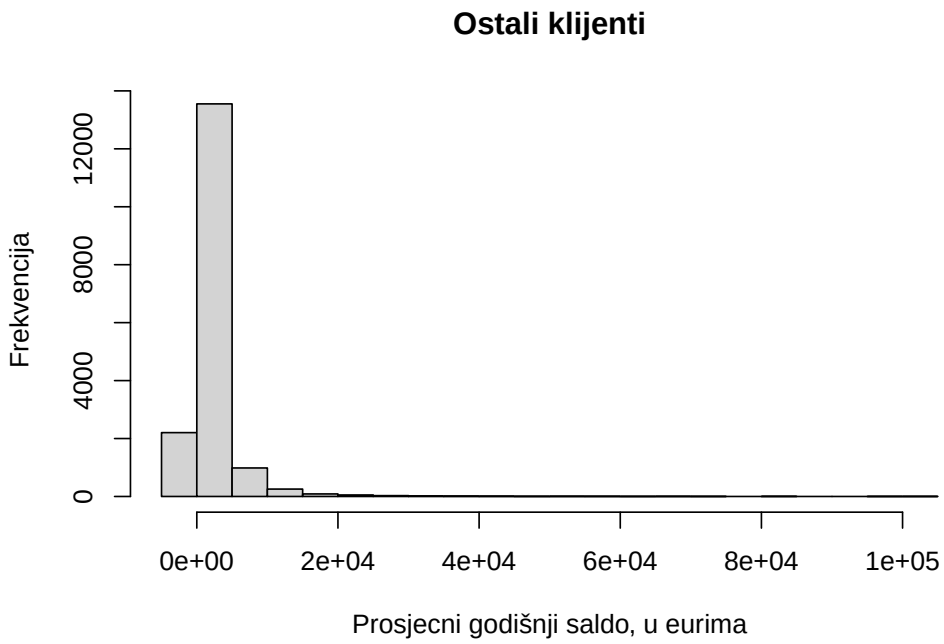
```
hist(balance_with_housing_loan,main='Klijenti s otvorenim stambenim kreditom',
     xlab='Prosječni godišnji saldo, u eurima', ylab='Frekvencija')
```



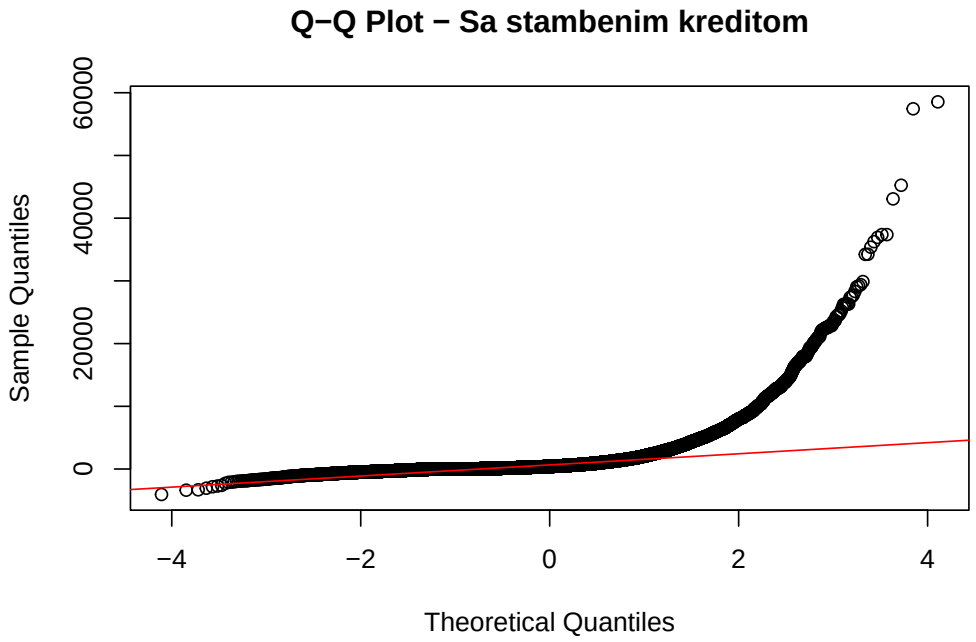

```
hist(balance_with_personal_loan,
     main='Klijenti s otvorenim nenamijenskim kreditom',
     xlab='Prosječni godišnji saldo, u eurima', ylab='Frekvencija')
```



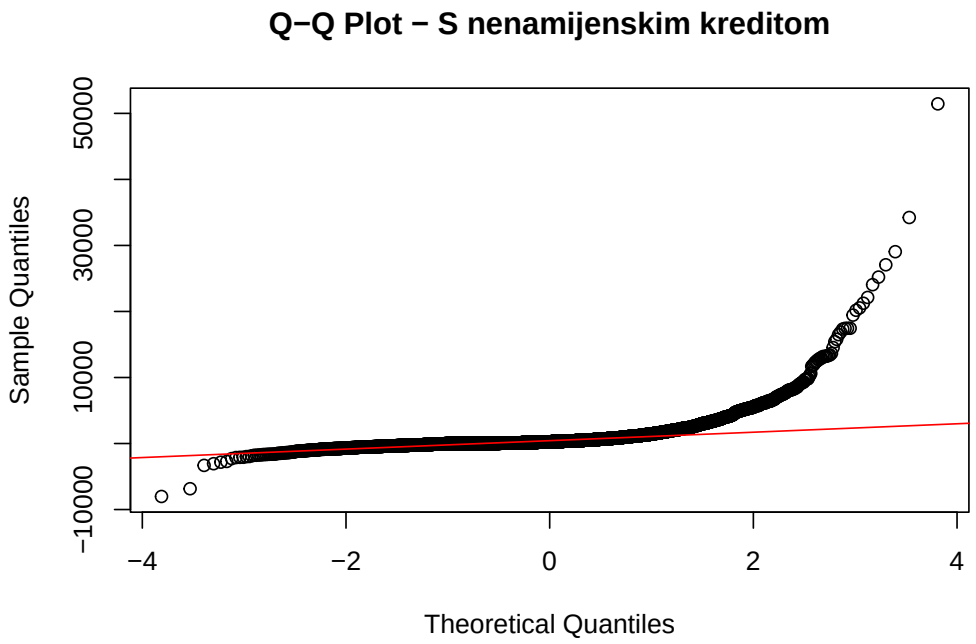

```
hist(balance_without_loan,main='Ostali klijenti',
     xlab='Prosječni godišnji saldo, u eurima', ylab='Frekvencija')
```



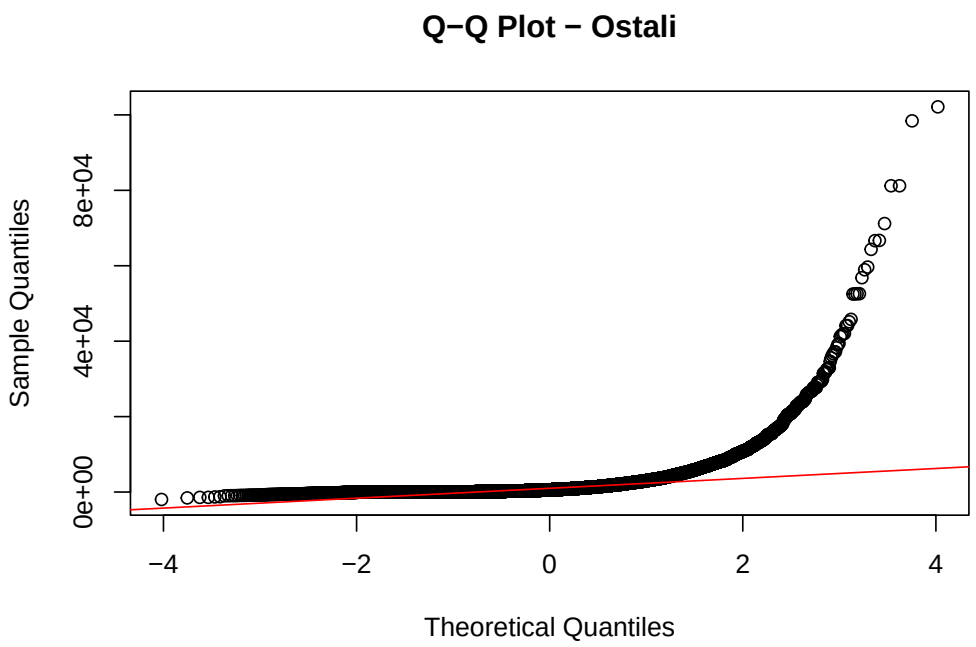

```
qqnorm(balance_with_housing_loan, main = "Q-Q Plot - Sa stambenim kreditom")
qqline(balance_with_housing_loan, col = "red")
```




```
qqnorm(balance_with_personal_loan,
       main = "Q-Q Plot - S nenamijenskim kreditom")
qqline(balance_with_personal_loan, col = "red")
```




```
qqnorm(balance_without_loan, main = "Q-Q Plot - Ostali")
qqline(balance_without_loan, col = "red")
```



Iz grafova se vizualno može očitati jesu li podaci normalno distribuirani ili ne. U slučaju histograma, podaci su normalno distribuirani ako je graf simetričan i zvonolikog oblika. Na našim histogramima se jasno može vidjeti kako podaci nisu normalno distribuirani jer graf nije niti simetričan niti zvonolikog oblika. Osim histograma, za provjeru normalne distribucije koristimo i Q-Q plot. S Q-Q plota također možemo vrlo jendostavno isčitati jesu li podaci normalno distribuirani; što točke više prate crvenu liniju, podaci su bliži normalnoj razdiobi. S istrtanih Q-Q plotova također vidimo da podaci ne prate u potpunosti normalnu razdiobu zbog točaka na desnom kraju koje su dosta udaljene od pravca.

Možemo zaključiti da podaci o stanju računa klijenata s stambenim ili nenamijenskim kreditom te onima bez istoga imaju sličnu distribuciju koja je zbog stršećih vrijednosti udaljena od normalne.

Kako bismo to popravili i približili se normalnoj distribuciji, pokušat ćemo srezat podatke odozgo i odozdo za 10%.

```
trim_data <- function(data, column, lower_percentile = 0.1,
                      upper_percentile = 0.9) {
```

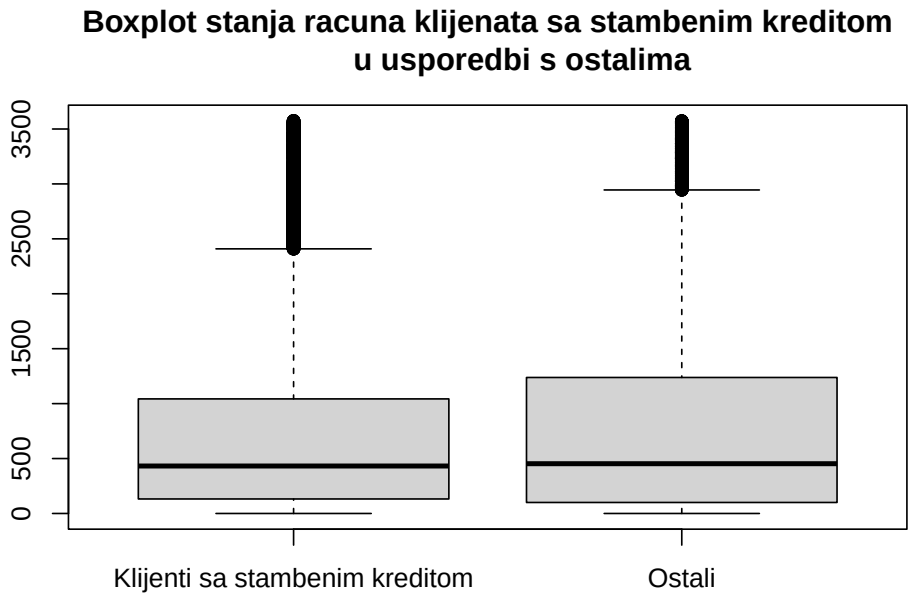
```
  lower_bound <- quantile(data[[column]], lower_percentile, na.rm = TRUE)
  upper_bound <- quantile(data[[column]], upper_percentile, na.rm = TRUE)

  trimmed_data <- data[data[[column]] >= lower_bound & data[[column]]
                       <= upper_bound, ]

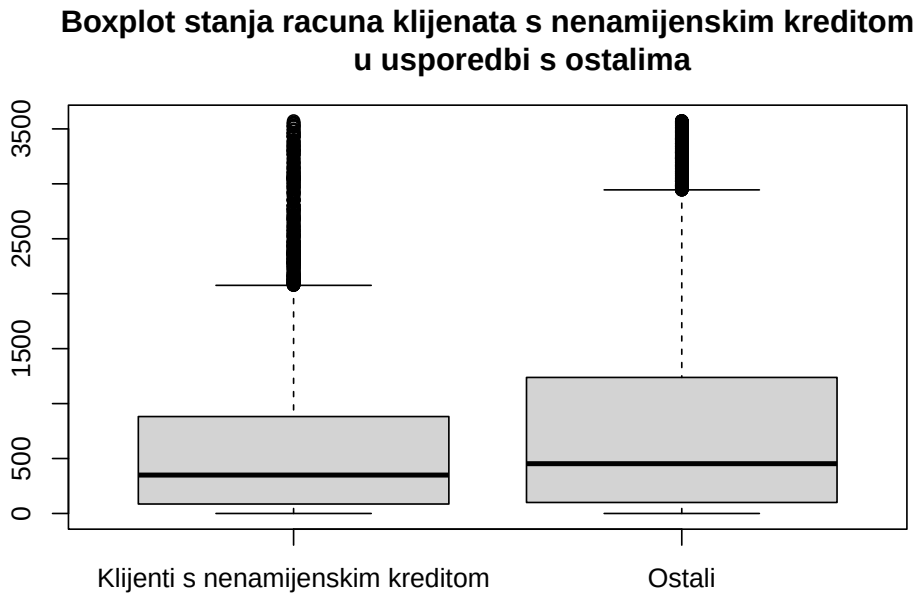
  return(trimmed_data)
}

trimmed_data <- trim_data(data, "balance", 0.10, 0.90)
balance_with_housing_loan <- trimmed_data$balance[
                                  trimmed_data$housing_loan == "yes"]
balance_without_loan <- trimmed_data$balance[trimmed_data$housing_loan == "no"
                                          & trimmed_data$personal_loan == "no"]
balance_with_personal_loan <- trimmed_data$balance[
                             trimmed_data$personal_loan == "yes"]
```

```
boxplot(balance_with_housing_loan, balance_without_loan,
        names = c('Klijenti sa stambenim kreditom',
                  'Ostali'),
        main='Boxplot stanja računa klijenata sa stambenim kreditom
        u usporedbi s ostalima')
```

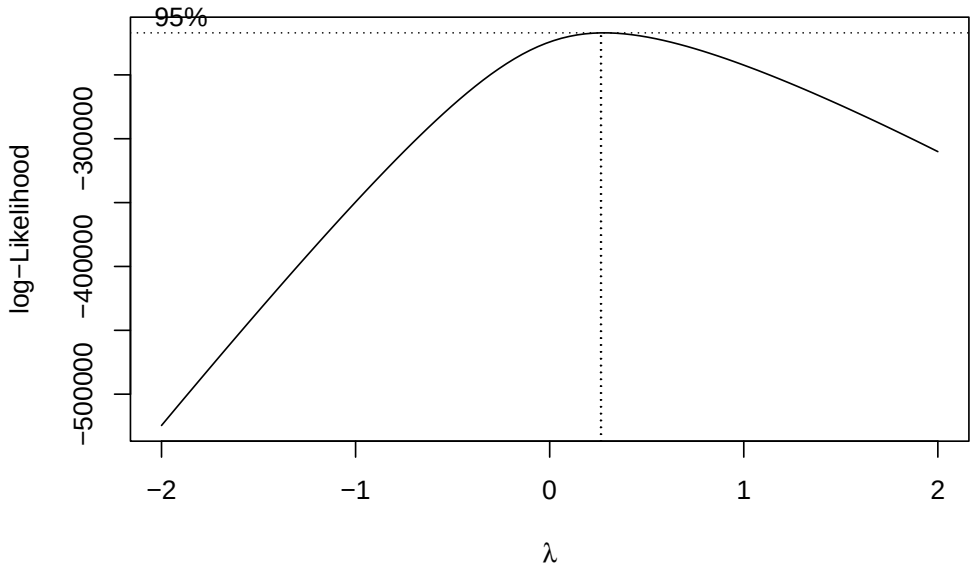



```
boxplot(balance_with_personal_loan, balance_without_loan,
        names = c('Klijenti s nenamijenskim kreditom',
                  'Ostali'),
        main='Boxplot stanja računa klijenata s nenamijenskim kreditom
        u usporedbi s ostalima')
```



Iz grafova možemo vdijeti da su stršeće vrijendosti i dalje prisutne, kako bismo olakšali daljnju analizu i podatke približili normalnoj distribuciji, transformirat ćemo ih Box-Cox transformacijom.

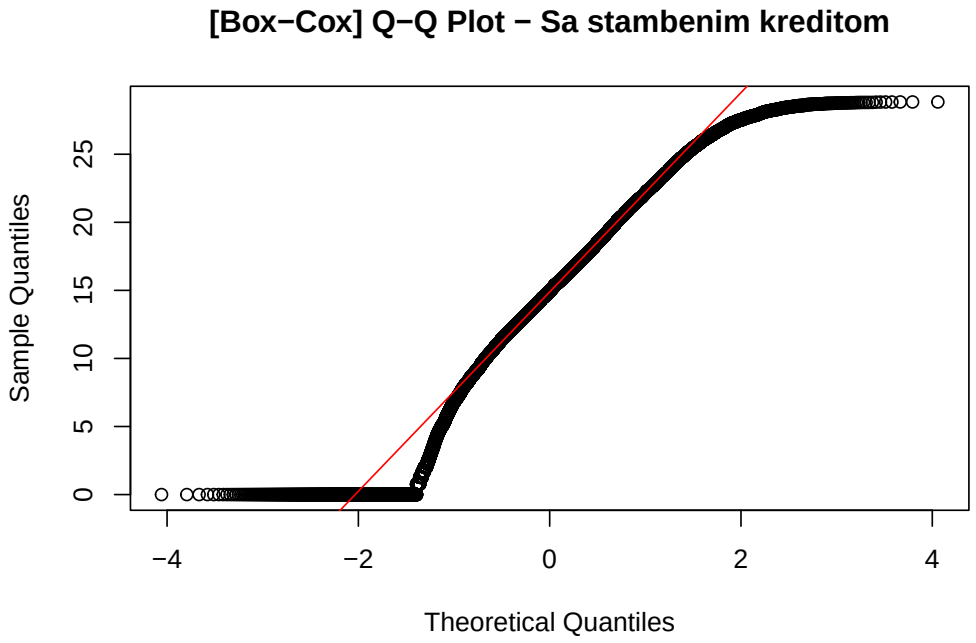
```
#s obzirom da među našim podacima ima i negativnih vrijednosti, prvo ćemo
# apsolutno vrijednost najmanjeg broja dodati na cijeli skup balance kako bismo
#mogli primijeniti Box-Cox transformaciju koja se može primijeniti isključivo
#na pozitivne brojeve
library(MASS)
min_val <- abs(min(trimmed_data$balance, na.rm = TRUE)) + 1
trimmed_data$balance <- trimmed_data$balance + min_val
boxcox_with_housing <- boxcox(lm(trimmed_data$balance ~ 1),
                              lambda = seq(-2, 2, 0.1),
                              plotit = TRUE)
```



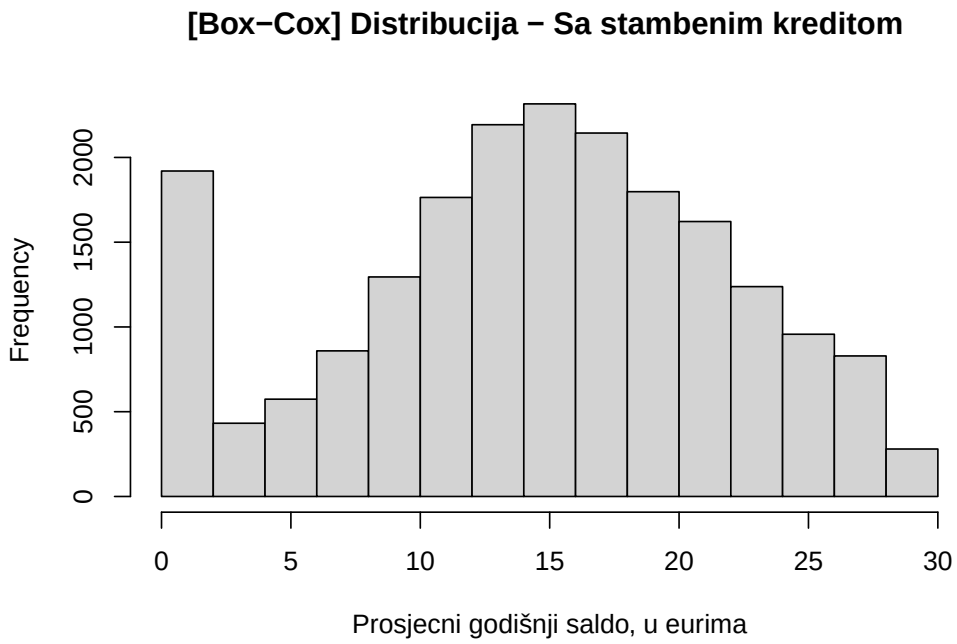

```
optimal_lambda_with_housing <-
  boxcox_with_housing$x[which.max(boxcox_with_housing$y)]

if (optimal_lambda_with_housing == 0) {
  trimmed_data$balance_boxcox <- log(trimmed_data$balance)
} else {
  trimmed_data$balance_boxcox <-
    ((trimmed_data$balance)^optimal_lambda_with_housing - 1) /
    optimal_lambda_with_housing
}
balance_with_housing_loan_boxcox <-
  trimmed_data$balance_boxcox[trimmed_data$housing_loan == "yes"]
balance_without_loan_boxcox <-
  trimmed_data$balance_boxcox[trimmed_data$housing_loan == "no" &
                                trimmed_data$personal_loan == "no"]
balance_with_personal_loan_boxcox <-
  trimmed_data$balance_boxcox[trimmed_data$personal_loan == "yes"]
```

```r
qqnorm(balance_with_housing_loan_boxcox,
       main = "[Box-Cox] Q-Q Plot - Sa stambenim kreditom")
qqline(balance_with_housing_loan_boxcox, col = "red")
```




```r
hist(balance_with_housing_loan_boxcox,
     main = "[Box-Cox] Distribucija - Sa stambenim kreditom ",
     xlab = "Prosječni godišnji saldo, u eurima")
```

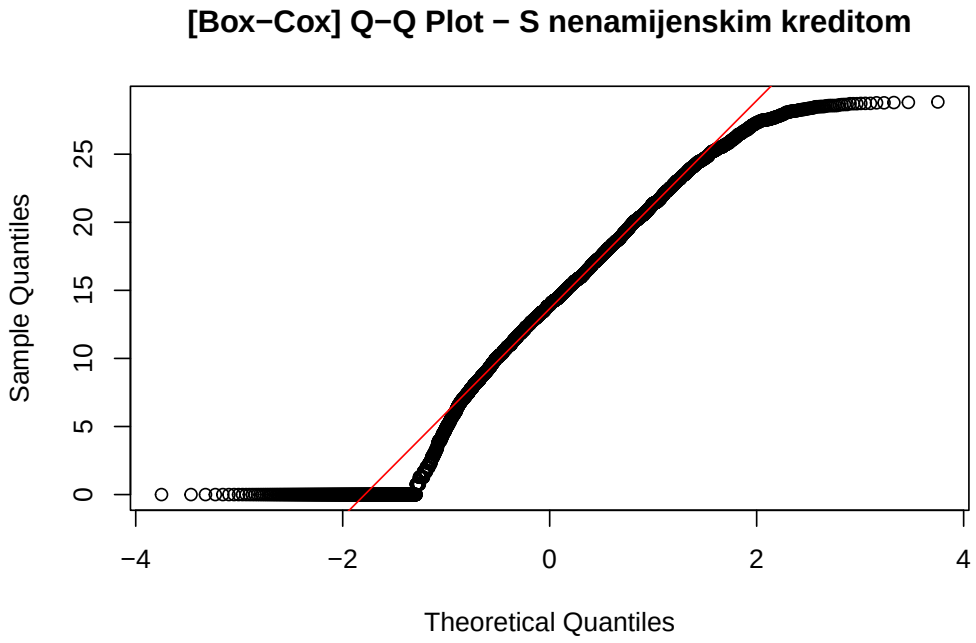



```
ks_test_with_personal_loan <- ks.test(
  jitter(balance_with_housing_loan_boxcox),
  "pnorm",
  mean = mean(balance_with_housing_loan_boxcox, na.rm = TRUE),
  sd = sd(balance_with_housing_loan_boxcox, na.rm = TRUE)
)

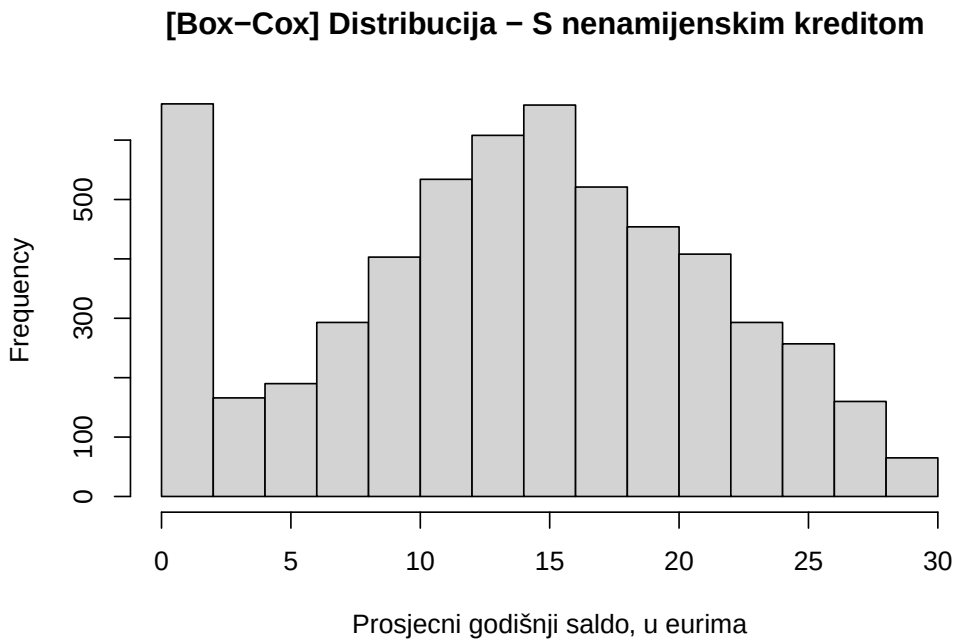
print(ks_test_with_personal_loan)
```

```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  jitter(balance_with_housing_loan_boxcox)
## D = 0.056071, p-value < 2.2e-16
## alternative hypothesis: two-sided
```

```r
qqnorm(balance_with_personal_loan_boxcox,
       main = "[Box-Cox] Q-Q Plot - S nenamijenskim kreditom")
qqline(balance_with_personal_loan_boxcox, col = "red")
```



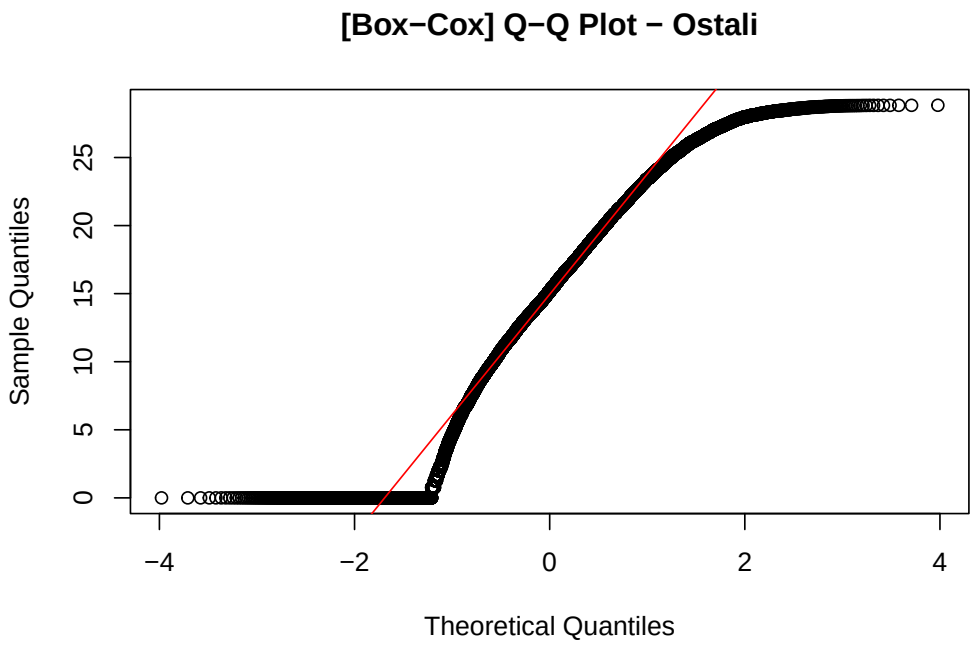

```r
hist(balance_with_personal_loan_boxcox,
     main = "[Box-Cox] Distribucija - S nenamijenskim kreditom ",
     xlab = "Prosječni godišnji saldo, u eurima")
```



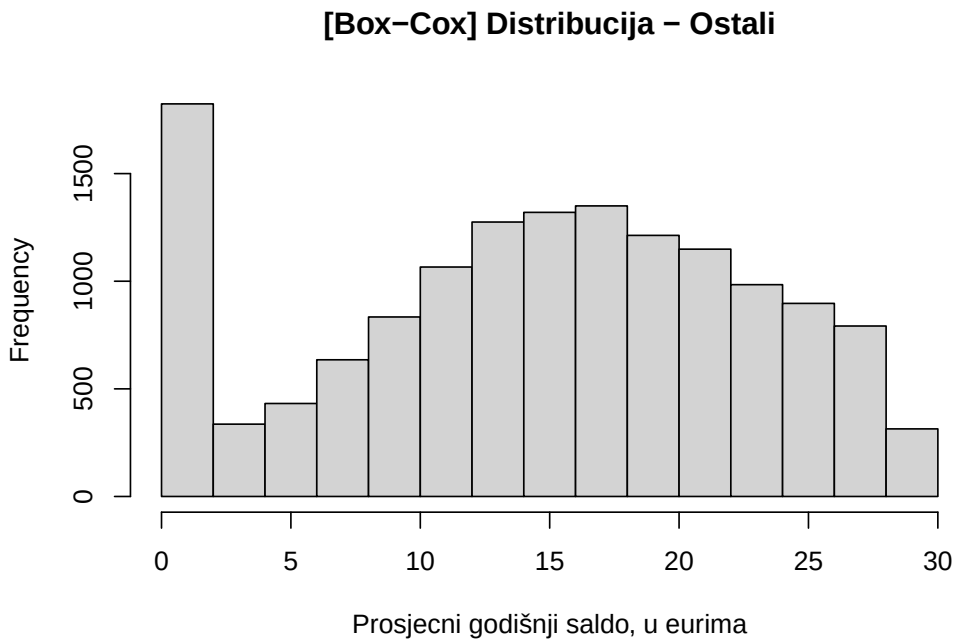

```
ks_test_with_personal_loan <- ks.test(
  jitter(balance_with_personal_loan_boxcox),
  "pnorm",
  mean = mean(balance_with_personal_loan_boxcox, na.rm = TRUE),
  sd = sd(balance_with_personal_loan_boxcox, na.rm = TRUE)
)
print(ks_test_with_personal_loan)
```

```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  jitter(balance_with_personal_loan_boxcox)
## D = 0.061283, p-value < 2.2e-16
## alternative hypothesis: two-sided
```

```
qqnorm(balance_without_loan_boxcox, main = "[Box-Cox] Q-Q Plot - Ostali")
qqline(balance_without_loan_boxcox, col = "red")
```




```
hist(balance_without_loan_boxcox, main = "[Box-Cox] Distribucija - Ostali",
     xlab = "Prosječni godišnji saldo, u eurima")
```




```
# KS test
ks_test_without_loans <- ks.test(
  jitter(balance_without_loan_boxcox),
  "pnorm",
  mean = mean(balance_without_loan_boxcox, na.rm = TRUE),
  sd = sd(balance_without_loan_boxcox, na.rm = TRUE)
)

print(ks_test_without_loans)
```

```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  jitter(balance_without_loan_boxcox)
## D = 0.074134, p-value < 2.2e-16
## alternative hypothesis: two-sided
```

Nakon provedenih transformacija možemo jasno uočiti promjene na

grafovima, uspješno smo približili podatke normalnoj distribuciji. Zbog i dalje postojanih stršećih vrijednosti, krajevi grafova su udaljeni od pravca, no većina točaka se ipak nalazi na pravcu koji ukazuje na normalnu distribuciju. KS test izračunava p-vrijednost manju od 0.05 zbog koje bismo trebali odbaciti hipotezu H_0 u korist hipoteze H_1 odnosno trebali bismo odbaciti hipotezu da su podaci normalno distribuirani. Iako KS test ne pokazuje normalnu distribucij, iz grafova možemo zaključiti da smo unatoč velikom broju stršećih vrijednosti, uspjeli podatke približiti normalnoj distribuciji. S obzirom na to da je t-test dosta robusan, primijenit ćemo ga nad našim podacima unatoč tome što nisu savršeno normalno distribuirani. Uzimajući u obzir da su klijenti nezavisni jedni od drugih, pretpostavljamo da vrijedi nezavisnost među podacima.

Nakon što smo potvrdili početne pretpostavke možemo nastaviti s analizom.

Prije provedbe samog t-testa moramo provjeriti jednakost varijanci.

```
# F-test za usporedbu varijanci
var.test(balance_with_housing_loan_boxcox, balance_without_loan_boxcox)
```

```
##
##  F test to compare two variances
##
## data:  balance_with_housing_loan_boxcox and balance_without_loan_boxcox
## F = 0.81734, num df = 20220, denom df = 14420, p-value < 2.2e-16
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.7929807 0.8423747
## sample estimates:
## ratio of variances
##          0.8173363
```

```
var.test(balance_with_personal_loan_boxcox, balance_without_loan_boxcox)
```

```
##
##  F test to compare two variances
##
```

```
## data:  balance_with_personal_loan_boxcox and balance_without_loan_boxcox
## F = 0.8401, num df = 5671, denom df = 14420, p-value = 8.857e-15
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.8045481 0.8775904
## sample estimates:
## ratio of variances
##          0.8401009
```

S obzirom na to da varijance nisu jednake u nijednom od dva slučaja (p je jako mali), primijenit ćemo t-test za podatke s različitim varijancama (Welchov t-test).

Napravit ćemo dva odvojena testa, prvo ćemo postaviti hipoteze za stambeni kredit. H_0:Klijenti s otvorenim stambenim kreditom nemaju više novca na računu u odnosu na ostale klijente. H_1:Klijenti s otvorenim stambenim kreditom imaju više novca na računu u odnosu na ostale klijente.

```
# Provedba Welchovog t-testa (jednostrani test: Sa kreditom > Bez kredita)
t_test_result <- t.test(balance_with_housing_loan_boxcox,
                        balance_without_loan_boxcox,
                        alternative = "greater",
                        var.equal = FALSE)

print(t_test_result)
```

```
##
##  Welch Two Sample t-test
##
## data:  balance_with_housing_loan_boxcox and balance_without_loan_boxcox
## t = -0.39383, df = 29083, p-value = 0.6531
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
##  -0.1755667        Inf
## sample estimates:
## mean of x mean of y
##  14.45118  14.48509
```

A zatim i za nenamijenski kredit:

H_0:Klijenti s otvorenim nenamijenskim kreditom nemaju više novca na računu u odnosu na ostale klijente. H_1:Klijenti s otvorenim nenamijenskim kreditom imaju više novca na računu u odnosu na ostale klijente.

```
t_test_result <- t.test(balance_with_personal_loan_boxcox,
                        balance_without_loan_boxcox,
                        alternative = "greater",
                        var.equal = FALSE)

print(t_test_result)
```

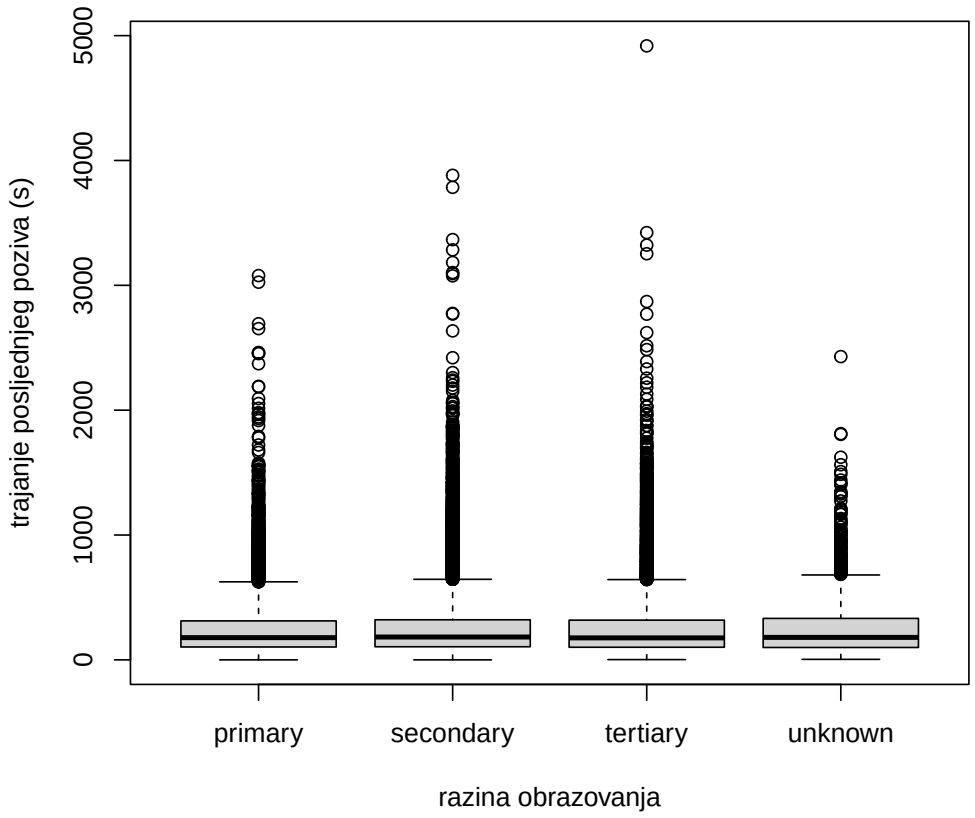
```
##
##  Welch Two Sample t-test
##
## data:  balance_with_personal_loan_boxcox and balance_without_loan_boxcox
## t = -8.6472, df = 11254, p-value = 1
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
##  -1.247518       Inf
## sample estimates:
## mean of x mean of y
##  13.43696  14.48509
```

S obzirom da je p-vrijednost u oba slučaja veća od 0.05, ne možemo odbaciti nul-hipotezu H_0 u koristi hipoteze H_1. Zaključujemo da klijenti s otvorenim kreditom (stambenim ili nenamijenskim) nemaju više novaca na računu od ostalih klijenata.

Razlika trajanja poziva među klijentima različite razine obrazovanja

Vizualizirajmo razine obrazovanja i pripadna trajanja poziva.

```r
boxplot(last_contact_duration~education,
        data=data,
        boxwex = 0.8,
        xlab="razina obrazovanja",
        ylab="trajanje posljednjeg poziva (s)")
```

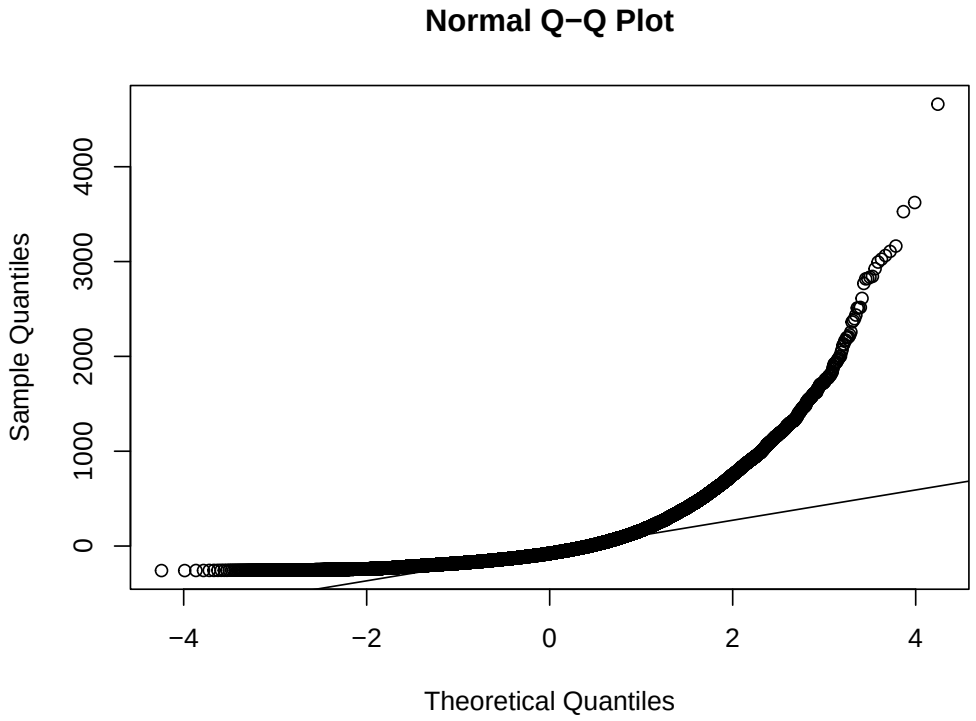


Pokušajmo prvo odgovoriti na istraživačko pitanje **ANOVA** testom o jednakosti prosjeka trajanja među razinama obrazovanja.

Prva pretpostavka ANOVA-e je da reziduali dolaze iz normalne distribucije.

```r
# prvo trebamo izračunati reziduale - pomoću aov
anova_model <- aov(last_contact_duration ~ education,
                   data = data)
reziduali_prije <- residuals(anova_model)

qqnorm(reziduali_prije)
qqline(reziduali_prije)
```



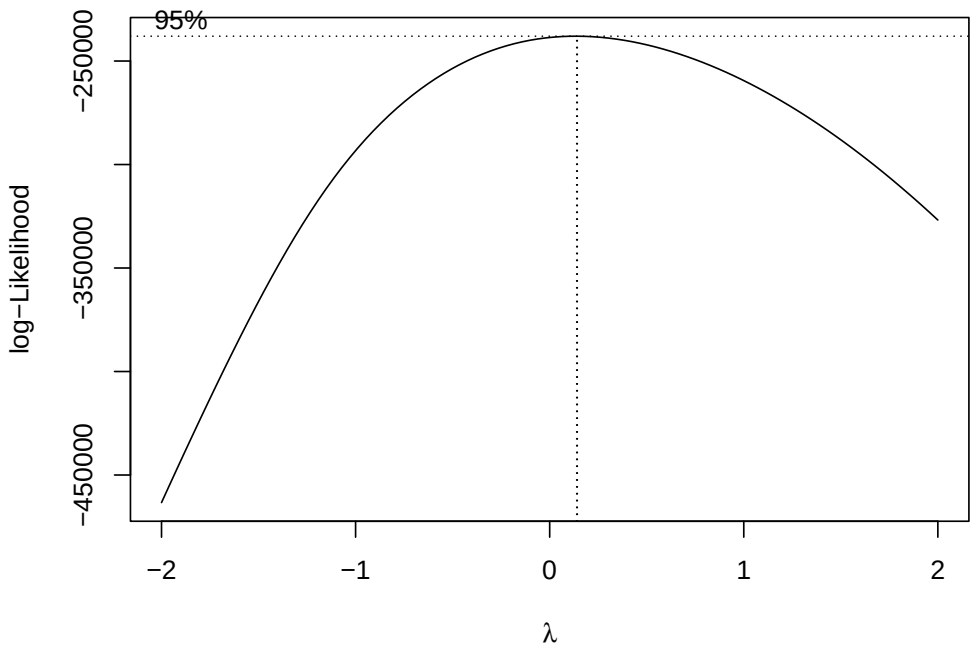
Q-Q vizualizacija služi za vizualnu "provjeru" normalnosti skupa podataka. Što točke bliže "prate" nacrtanu dužinu, to normalna distribucija bolje opisuje dani skup podataka. Na Q-Q plotu reziduala vidimo izrazito odstupanje, posebice na rubovima dužine. To sugerira da reziduali nisu normalno distribuirani te da na njima ne možemo provesti ANOVA test.

Pokušajmo na transformiranim podacima.

```r
library(MASS)

# Provest ćemo Box-Cox transformaciju, koja zahtijeva
# da su podaci pozitivni. U našem skupu podataka ima
# mnogo poziva duljine 0, pa ćemo cijeli skup
# podataka pomaknuti.
data$last_contact_duration_p1 <- data$last_contact_duration + 1

# Provedimo Box-Cox transformaciju da bismo
# smanjili varijancu
# (https://encyclopediaofmath.org/wiki/Box-Cox_transformation)
boxcox_result <- boxcox(aov(last_contact_duration_p1
                            ~ education,
                            data = data),
                        lambda = seq(-2, 2, by = 0.1))
```

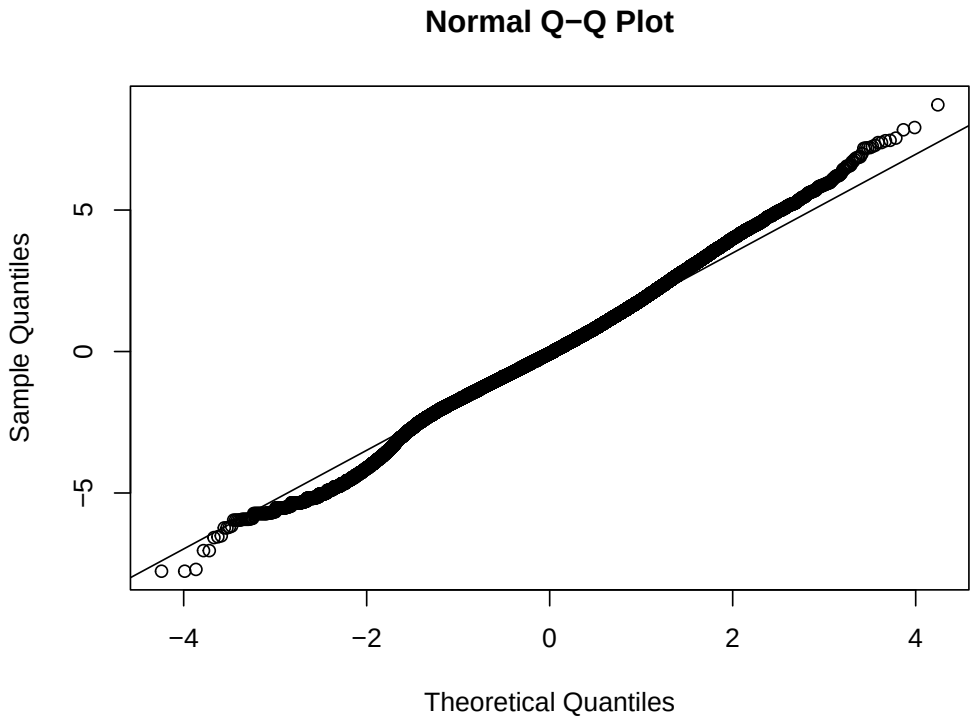


```r
lambda_opt <- boxcox_result$x[which.max(boxcox_result$y)]

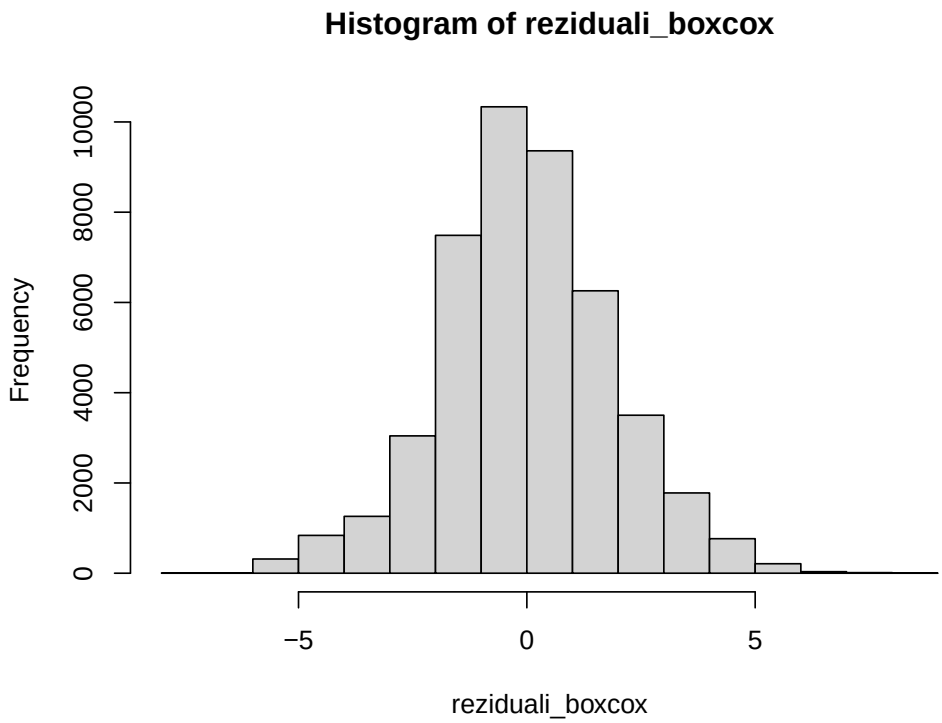
if (lambda_opt == 0) {
  data$boxcox_last_contact_duration <-
    log(data$last_contact_duration_p1)
} else {
  data$boxcox_last_contact_duration <-
    (data$last_contact_duration_p1^lambda_opt - 1) / lambda_opt
}

# Izračunajmo reziduale za transformirane podatke
anova_model_boxcox <- aov(boxcox_last_contact_duration
                          ~ education,
                          data = data)
reziduali_boxcox <- residuals(anova_model_boxcox)

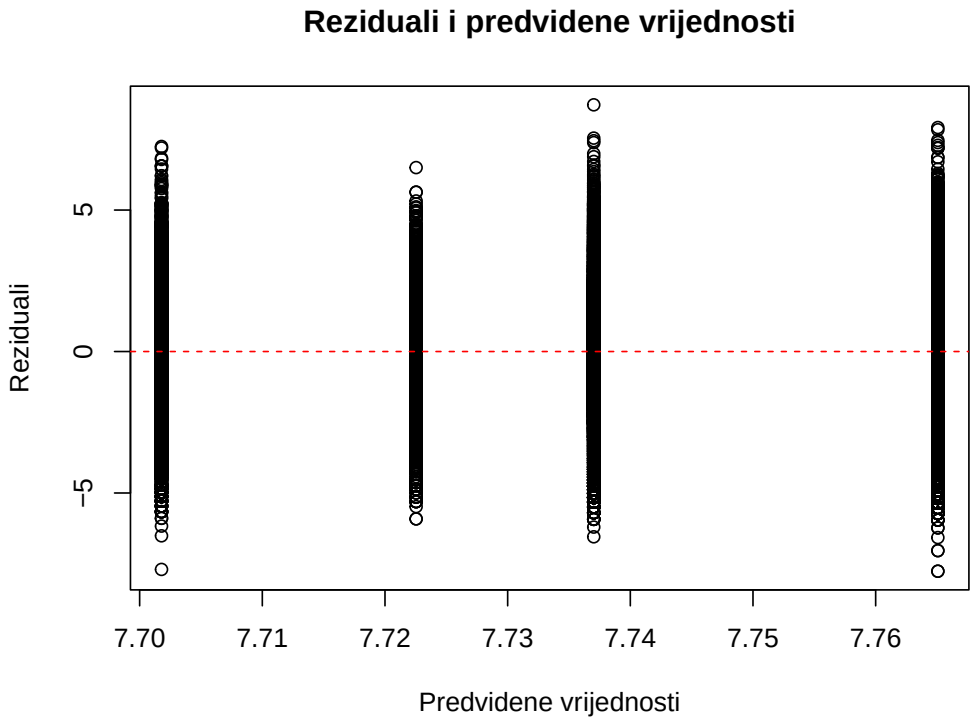
# Pogledajmo ih na Q-Q plotu
qqnorm(reziduali_boxcox)
qqline(reziduali_boxcox)
```




```
hist(reziduali_boxcox)
```




```
# residuals - fitted values plot
# anova model predviđa vrijednosti
# https://www.geeksforgeeks.org/how-to-extract-the-residuals-and-predicted-value
plot(fitted(anova_model_boxcox), residuals(anova_model_boxcox),
     xlab = "Predviđene vrijednosti",
     ylab = "Reziduali",
     main = "Reziduali i predviđene vrijednosti")
abline(h = 0, col = "red", lty = 2)
```



Iz gornjih vizualizacija donosimo odluku da su dovoljno zadovoljene pretpostavke ANOVA testa, koji sad provodimo.

```
summary(anova_model_boxcox)
```

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## education       3     24   7.972   2.234 0.0821 .
## Residuals   45207 161331   3.569
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Zato što je p-vrijednost $p = 0.0821 > 0.05 = \alpha$, na razini značajnosti $\alpha = 0.05$ zaključujemo da iz podataka **ne uočavamo statistički značajnu razliku u prosječnom trajanju poziva klijentima različitih stupnjeva obrazovanja**.

Ipak, možda nas radi unaprjeđenja usluga više zanima razlikuju li se **medijani** duljina trajanja poziva po skupinama. Primjerice, u redu nam je imati neke klijente koji svojim duljim pozivima povećavaju prosjek svoje skupine, ali voljeli bismo robusniju mjeru toga razgovaramo li s čitavom skupinom dulje nego s ostalima.

Iz tog razloga provest ćemo i neparametarski **Kruskal-Wallisov test** s 12. predavanja. Jedini uvjet za taj test koji nam različite razine obrazovanja moraju zadovoljavati jest da za svaku razinu obrazovanja postoji 5 ili više klijenata te razine obrazovanja. To je zadovoljeno:

```
tablica_frekv <- as.data.frame(table(data$education))
colnames(tablica_frekv) <- c("razina obrazovanja",
                             "broj klijenata")
print(tablica_frekv)
```

```
##   razina obrazovanja broj klijenata
## 1            primary           6851
## 2          secondary          23202
## 3           tertiary          13301
## 4            unknown           1857
```

Provedimo dakle test; nulta hipoteza H_0 je da se medijani trajanja poziva **ne** razlikuju među grupama klijenata različitih razina obrazovanja.

```
kruskal_test <- kruskal.test(last_contact_duration ~ education,
                             data = data)
print(kruskal_test)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  last_contact_duration by education
## Kruskal-Wallis chi-squared = 11.43, df = 3, p-value = 0.009614
```

Uočimo da je dobivena p-vrijednost $p = 0.009614$, pa (jer $p < 0.05$) na razini značajnosti α=0.05 **odbacujemo** hipotezu H_0 u korist alternativne hipoteze, te zaključujemo da **postoji statistički značajna razlika**

u medijanima duljina poziva s klijentima različitih razina obrazovanja.

Dakle, možemo zaključiti da, ovisno o načinu na koji postavimo pitanje, dobivamo različite odgovore. U *prosjeku*, izgleda da podaci ne pokazuju da se skupine određene razinama obrazovanja razlikuju po trajanjima poziva. Ipak, nismo detaljnije provjeravali pretpostavke ANOVA testa, pa je moguće da nam neparametarski Kruskal-Wallisov test daje bolji odgovor. Svakako možemo zaključiti da među trajanjima poziva klijentima različitih razina obrazovanja ipak postoji razlika, makar ne bila u prosjeku.

Predviđanje uspješnosti ?

Želimo saznati mogu li dostupne varijable predvidjeti uspješnost marketinške kampanje. Želimo dobiti VJEROJATNOST je li klijent uplatio oročeni depozit tj. je li aktualna kampanja uspješna. Ciljna binarna varijabla je term_deposit_accepted. S obzirom da želimo vjerojatnost, ne možemo koristiti linearnu regresiju jer kod nje regresori mogu poprimiti vrijednosti i izvan [0,1] što onda nije vjerojatnost. Zato ćemo na pitanje pokušati odgovoriti pomoću logističke regresije. Osim toga, to je logičan izbor jer se radi o klasifikaciji.

Logistička regresija radi procjenu na principu maksimalne izglednosti.

Za razliku od linearne regresije, normalnost reziduala nije pretpostavka logističke regresije. Njezine pretpostavke su nezavisnost opažanja što je zadovoljeno i da nema visoke koreliranosti među regresorima. To ćemo kasnije, nakon izgeneriranog summaryja modela, provjeriti VIF testom.

Sad ćemo pogledati imamo li NA vrijednosti i koliko ih je unknown tj. nepoznatih. To nam otežava analizu, ali može donijeti i nove informacije. Na primjer, pogledajmo koliko se puta pojavljuje 0 po varijablama/stupcima.

```
data <- read.csv("/Users/Home/Desktop/SAP projekt/data.csv")
colSums(data == 0)
```

```
##                       age                       job
##                         0                         0
##            marital_status                 education
```

```
##                                   0                                   0
##                             default                             balance
##                                   0                                3514
##                         housing_loan                       personal_loan
##                                   0                                   0
##                             contact                     last_contact_day
##                                   0                                   0
##                  last_contact_month               last_contact_duration
##                                   0                                   3
##             campaign_contacts_count days_from_previous_campaign_contact
##                                   0                                   0
##             previous_contacts_count           previous_campaign_outcome
##                               36954                                   0
##               term_deposit_accepted
##                                   0
```

Vidimo da se u previous_contacts_count 0 pojavljuje 36954 puta. Toliko klijenata (primjera) uopće nisu zvali prije ove kampanje. Pogledajmo sad NA i unknown.

```
print("Broj NA u datasetu:")
```

```
## [1] "Broj NA u datasetu:"
```

```
sum(!complete.cases(data))
```

```
## [1] 0
```

```
print("Po stupcima unknown se pojavljuje ovoliko puta:")
```

```
## [1] "Po stupcima unknown se pojavljuje ovoliko puta:"
```

```
sapply(data, function(x) sum(x == "unknown"))
```

```
##                                 age                                 job
##                                   0                                 288
##                      marital_status                           education
##                                   0                                1857
##                             default                             balance
##                                   0                                   0
##                        housing_loan                       personal_loan
##                                   0                                   0
##                             contact                     last_contact_day
##                               13020                                   0
##                  last_contact_month                last_contact_duration
##                                   0                                   0
##              campaign_contacts_count days_from_previous_campaign_contact
##                                   0                                   0
##              previous_contacts_count            previous_campaign_outcome
##                                   0                                36959
##                term_deposit_accepted
##                                   0
```

Vidimo da se unknown pojavljuje u više od 80% slučajeva kod varijable previous_campaign_outcome. To bi moglo biti problematično. Međutim, ako klijent dosad nije bio uključen u kampanju i ovo mu je prvi put, to bi mogla biti bitna informacija za model. previous_campaign_outcome još može poprimiti vrijednosti other, failure i success. Varijablama job i education također ne znamo određen broj vrijednost, ali to je u odnosu na ukupan broj primjera zanemarivo (izbacivanje ili imputacija medijanom).

Prvo ćemo ostaviti sve varijable kako su i bile i provesti logističku regresiju nad cijelim datasetom. Za početak ćemo chr varijable pretvoriti u factor jer to zahtijeva naš model. Numeričke varijable mogu ostati numeričke.

```
data$job= factor(data$job, levels = c('unknown','unemployed','retired','admin.'
  ,'management','technician','entrepreneur','blue-collar','housemaid','student'
  ,'services','self-employed'),labels = c(0,1,2,3,4,5,6,7,8,9,10,11))
data$marital_status = factor(data$marital_status, levels = c('married',
  'divorced', 'single'), labels = c(1,2,3))
data$education = factor(data$education, levels = c('unknown','primary',
  'secondary', 'tertiary'), labels = c(0,1,2,3))
```

```
data$default = factor(data$default, levels = c('no','yes'), labels = c(0,1))
data$housing_loan=factor(data$housing_loan,levels=c('no','yes'),labels=c(0,1))
data$personal_loan=factor(data$personal_loan,levels=c('no','yes'),labels=c(0,1))
data$contact = factor(data$contact, levels = c('unknown','telephone',
  'cellular'), labels = c(0,1,2))
data$last_contact_month = factor(data$last_contact_month, levels =
  c('jan','feb','mar','apr','may','jun','jul','aug','sep','oct','nov','dec'),
labels = c(1,2,3,4,5,6,7,8,9,10,11,12))
data$previous_campaign_outcome = factor(data$previous_campaign_outcome,
levels = c('unknown','other','failure','success'), labels = c(0,1,2,3))
data$term_deposit_accepted = factor(data$term_deposit_accepted, levels =
  c('no','yes'), labels = c(0,1))
```

Sad možemo provesti logističku regresiju.

```
logistic <- glm(term_deposit_accepted ~ ., data = data, family = binomial)
summary(logistic)
```

```
##
## Call:
## glm(formula = term_deposit_accepted ~ ., family = binomial, data = data)
##
## Coefficients:
##                                    Estimate Std. Error z value Pr(>|z|)
## (Intercept)                      -5.755e+00  2.936e-01 -19.601  < 2e-16 ***
## age                               1.127e-04  2.205e-03   0.051 0.959233
## job1                              1.366e-01  2.469e-01   0.553 0.580282
## job2                              5.656e-01  2.373e-01   2.384 0.017138 *
## job3                              3.133e-01  2.335e-01   1.342 0.179656
## job4                              1.480e-01  2.317e-01   0.639 0.523110
## job5                              1.372e-01  2.317e-01   0.592 0.553700
## job6                             -4.384e-02  2.533e-01  -0.173 0.862619
## job7                              3.392e-03  2.328e-01   0.015 0.988376
## job8                             -1.907e-01  2.577e-01  -0.740 0.459187
## job9                              6.954e-01  2.452e-01   2.836 0.004570 **
## job10                             8.947e-02  2.374e-01   0.377 0.706261
```

```
## job11                                  1.493e-02  2.471e-01   0.060 0.951822
## marital_status2                        1.795e-01  5.891e-02   3.046 0.002318 **
## marital_status3                        2.720e-01  4.594e-02   5.919 3.23e-09 ***
## education1                            -2.505e-01  1.039e-01  -2.411 0.015915 *
## education2                            -6.695e-02  9.124e-02  -0.734 0.463085
## education3                             1.285e-01  9.586e-02   1.340 0.180204
## default1                              -1.668e-02  1.628e-01  -0.102 0.918407
## balance                                1.283e-05  5.148e-06   2.493 0.012651 *
## housing_loan1                         -6.754e-01  4.387e-02 -15.395  < 2e-16 ***
## personal_loan1                        -4.254e-01  5.999e-02  -7.091 1.33e-12 ***
## contact1                               1.460e+00  1.006e-01  14.508  < 2e-16 ***
## contact2                               1.623e+00  7.317e-02  22.184  < 2e-16 ***
## last_contact_day                       9.969e-03  2.497e-03   3.993 6.53e-05 ***
## last_contact_month2                    1.114e+00  1.321e-01   8.435  < 2e-16 ***
## last_contact_month3                    2.852e+00  1.522e-01  18.735  < 2e-16 ***
## last_contact_month4                    1.262e+00  1.217e-01  10.367  < 2e-16 ***
## last_contact_month5                    8.626e-01  1.210e-01   7.131 9.96e-13 ***
## last_contact_month6                    1.715e+00  1.342e-01  12.781  < 2e-16 ***
## last_contact_month7                    4.309e-01  1.198e-01   3.597 0.000322 ***
## last_contact_month8                    5.678e-01  1.211e-01   4.688 2.76e-06 ***
## last_contact_month9                    2.136e+00  1.522e-01  14.034  < 2e-16 ***
## last_contact_month10                   2.143e+00  1.411e-01  15.193  < 2e-16 ***
## last_contact_month11                   3.883e-01  1.246e-01   3.115 0.001836 **
## last_contact_month12                   1.953e+00  1.995e-01   9.788  < 2e-16 ***
## last_contact_duration                  4.194e-03  6.453e-05  64.986  < 2e-16 ***
## campaign_contacts_count               -9.078e-02  1.014e-02  -8.955  < 2e-16 ***
## days_from_previous_campaign_contact -1.027e-04  3.061e-04  -0.335 0.737268
## previous_contacts_count                1.015e-02  6.503e-03   1.561 0.118476
## previous_campaign_outcome1             2.953e-01  1.068e-01   2.766 0.005677 **
## previous_campaign_outcome2             9.179e-02  9.347e-02   0.982 0.326093
## previous_campaign_outcome3             2.383e+00  8.625e-02  27.627  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 32631  on 45210  degrees of freedom
## Residual deviance: 21562  on 45168  degrees of freedom
```

```
## AIC: 21648
##
## Number of Fisher Scoring iterations: 6
```

```
require(caret)
```

```
## Loading required package: caret
```

```
## Loading required package: lattice
```

```
Rsq = 1 - logistic$deviance/logistic$null.deviance
Rsq
```

```
## [1] 0.3392081
```

Koliko je model dobar govori nam residual deviance. Model je bolji što je ta vrijednost manja. Postoji i AIC gdje također tražimo što manju vrijednost. Još jedna provjera je i matrica zabune.

Uz R_i^2, koeficijent determinacije iz pomoćne regresije prediktora X_i na ostale prediktore, Variance Inflation Factor (VIF) definiran je kao:

$$VIF_i = \frac{1}{1 - R_i^2}.$$

Variance Inflation Factor mjeri koliko višekolinearnost među prediktorima povećava varijancu procijenjenih koeficijenata.

```
library(car)
```

```
## Loading required package: carData
```

```
vif_values <- vif(logistic)
print(vif_values)
```

```
##                                        GVIF Df GVIF^(1/(2*Df))
## age                                2.180880  1        1.476780
## job                                4.165825 11        1.067009
## marital_status                     1.444128  2        1.096229
## education                          2.257484  3        1.145348
## default                            1.016611  1        1.008271
## balance                            1.042409  1        1.020984
## housing_loan                       1.428124  1        1.195041
## personal_loan                      1.064119  1        1.031561
## contact                            1.902585  2        1.174454
## last_contact_day                   1.343766  1        1.159209
## last_contact_month                 3.744738 11        1.061854
## last_contact_duration              1.126210  1        1.061231
## campaign_contacts_count            1.106459  1        1.051883
## days_from_previous_campaign_contact 3.665840  1        1.914638
## previous_contacts_count            1.278820  1        1.130849
## previous_campaign_outcome          4.217021  3        1.271065
```

Prema VIF testu zaključujemo da višekolinearnost nije problem jer su sve vrijednosti GVIF^(1/(2*Df)) manje od 2.

Sad ćemo pokušati dobiti bolje modele i bolju predikciju ciljne varijable tako što ćemo usporediti različite modele logističke regresije.

```
model_single <- glm(term_deposit_accepted ~ last_contact_duration,
                    family = binomial, data = data)


model_reduced <- glm(term_deposit_accepted ~ last_contact_duration +
                    housing_loan + personal_loan +
                    contact + last_contact_month + previous_campaign_outcome,
                    family = binomial, data = data)

model_full <- glm(term_deposit_accepted ~ ., family = binomial, data = data)
```

Za usporedbu će nam pomoći anova

```r
anova(model_single, model_reduced, model_full, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: term_deposit_accepted ~ last_contact_duration
## Model 2: term_deposit_accepted ~ last_contact_duration + housing_loan +
##     personal_loan + contact + last_contact_month + previous_campaign_outcome
## Model 3: term_deposit_accepted ~ age + job + marital_status + education +
##     default + balance + housing_loan + personal_loan + contact +
##     last_contact_day + last_contact_month + last_contact_duration +
##     campaign_contacts_count + days_from_previous_campaign_contact +
##     previous_contacts_count + previous_campaign_outcome
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1     45209      27502
## 2     45191      21907 18   5594.3 < 2.2e-16 ***
## 3     45168      21562 23    345.1 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nismo uspjeli dobiti bolji model, no model sa svim varijablama je statistički značajan uz p-vrijednost 0.05.